Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Ingeniería de prompts: cómo el contexto define la tarea

Diseño, ejemplos, razonamiento y evaluación

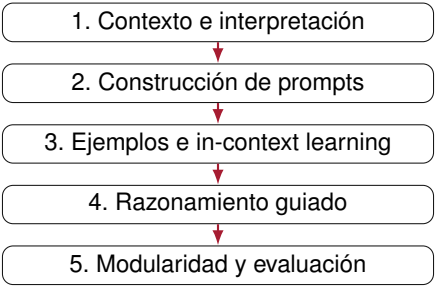
PhD. Oscar Rodríguez Meléndez

Universidad Nacional de Colombia

2026·II

DataLab UNAL

Ruta de trabajo



Idea conductora

Una instrucción no actúa sola: el contexto ayuda al modelo a decidir qué tarea debe resolver.

Escucha antes de leer

Instrucción

Escucha el audio una sola vez y escribe exactamente qué entendiste.

- No consultes la respuesta de otra persona.
- No intentes adivinar cuál es la opción correcta.
- Conserva por escrito tu primera interpretación.

Audio de la actividad

Reproducir audio

youtube.com/shorts/IEHw9I2vyXA

Idea clave

Primero escucha sin pistas: todavía no mostraremos las posibles interpretaciones.

¿Qué escuchaste?

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Primera interpretación

Escribe la frase completa que crees haber escuchado.

- ¿Todos entendieron la misma frase?
- ¿Hubo alguna palabra difícil de identificar?
- ¿Qué tan seguro estás de tu respuesta?

Todavía no busquemos la respuesta correcta

Primero observemos cuántas interpretaciones surgieron a partir del mismo audio.

DataLab UNAL

Escúchalo pensando en “alquiler”

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Posible interpretación

“Hija, ¿llevaste la plata del **alquiler** al padrino?”

Segunda escucha

Reproduce nuevamente el audio mientras lees esta frase.

- ¿Ahora escuchas “alquiler”?
- ¿Cambió algo frente a tu primera interpretación?
- ¿La pista visual modificó tu escucha?

DataLab UNAL

Ahora escúchalo pensando en “bicicleta”

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Otra interpretación

“Hija, ¿llevaste la plata de la **bicicleta** al padrino?”

Tercera escucha

Reproduce el mismo audio mientras lees esta nueva frase.

- ¿Escuchas ahora “bicicleta”?
- ¿Puedes alternar entre ambas interpretaciones?
- El audio no cambió. ¿Qué cambió?

DataLab UNAL

Un fenómeno viral en español

¿De dónde surgió?

En marzo de 2021, una nota de voz compartida en redes sociales generó dos interpretaciones principales.

Interpretación 1

“Hija, ¿llevaste la plata del **alquiler** al padrino?”

Interpretación 2

“Hija, ¿llevaste la plata de la **bicicleta** al padrino?”

Aclaración

La receptora del audio explicó posteriormente que la palabra era **bicicleta**.

Referencia periodística: La Sexta y TN, marzo de 2021.

Antes ocurrió algo parecido: Yanny o Laurel

Laboratorio de Analítica de Datos - Sede Bogotá

UNIVERSIDAD NACIONAL DE COLOMBIA

El fenómeno de 2018

Una grabación breve se hizo viral porque algunas personas escuchaban “Yanny”, mientras otras escuchaban “Laurel”.

- El fenómeno alcanzó gran difusión en mayo de 2018.
- Las características acústicas y los dispositivos explicaban parte de las diferencias.
- También se investigó cómo el contexto previo modificaba la percepción.

Pregunta relevante

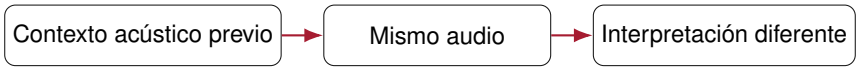
¿Puede una misma persona interpretar de manera diferente el mismo audio cuando cambia lo que escucha inmediatamente antes?

DataLab UNAL

El contexto previo modifica la percepción

Investigación de Hans Rutger Bosker

Bosker presentó el mismo audio ambiguo después de diferentes contextos acústicos y observó cambios en la interpretación de los participantes.



Idea clave

La señal actual no siempre se interpreta de manera aislada: el contexto anterior puede cambiar cómo la percibimos.

Bosker, H. R. (2018). *Putting Laurel and Yanny in context.*

Qué podemos concluir y qué no

Sí podemos concluir

- La interpretación depende del estímulo y del contexto.
- Las expectativas pueden orientar lo que percibimos.
- Una misma entrada puede admitir más de una lectura.

No debemos concluir

- Que un LLM percibe como una persona.
- Que la analogía describe exactamente sus operaciones internas.

Del audio al prompt

Una instrucción también puede ser ambigua

“Analiza estos resultados.”

- Describir tendencias
- Comparar periodos
- Identificar errores
- Explicar posibles causas
- Extraer conclusiones
- Recomendar acciones

Idea clave

La instrucción no cambia, pero el contexto puede hacer que represente tareas diferentes.

Pregunta guía

Cuando un modelo responde algo diferente a lo esperado,

¿interpretó mal nuestra solicitud

o construimos un contexto que le hizo resolver otra tarea?

Esta pregunta orientará el recorrido

Diseño del prompt → ejemplos → razonamiento → evaluación.

Objetivos de aprendizaje

Al finalizar estas sesiones, podrás:

- convertir una intención general en una tarea observable;
- construir prompts con contexto, reglas, ejemplos y formato;
- distinguir familias prácticas de tareas;
- usar estrategias zero-shot, one-shot y few-shot;
- seleccionar estrategias para problemas de varios pasos;
- modularizar, probar y mejorar prompts con criterios explícitos.

Idea central

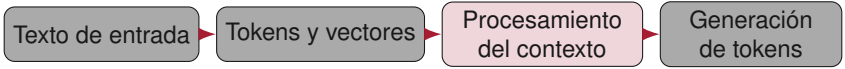
Un prompt útil no solo debe sonar bien: debe producir resultados verificables y robustos.

¿Qué es un LLM y cómo procesa el contexto?

Laboratorio de Analítica de Datos - Sede Bogotá -
UNIVERSIDAD NACIONAL DE COLOMBIA

Definición

Un **LLM** es un modelo de lenguaje que procesa el contexto y genera texto a partir de patrones aprendidos durante su entrenamiento.



- Un **token** puede ser una palabra, una parte de palabra o un símbolo.
- En la generación autorregresiva, el modelo predice tokens sucesivamente.
- La coherencia lingüística no garantiza que el contenido sea verdadero.

Fuente: Vaswani et al. (2017), Attention Is All You Need

DataLab UNAL

¿Qué es un prompt?

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Definición operativa

Un **prompt** es el contexto que proporcionamos a un modelo para representar una tarea y orientar la respuesta o acción esperada.

- Puede incluir objetivo, contexto, datos, restricciones, ejemplos y formato.
- Funciona como interfaz entre la intención humana y la predicción del modelo.
- Es el punto de partida del **prompt engineering**.

Ejemplo breve

“Resume este texto para estudiantes de primer semestre. Entrega tres ideas clave en viñetas y evita términos técnicos sin explicación.”

DataLab UNAL

El verbo no define la tarea

Verbos frecuentes

- Analiza.
- Resume.
- Clasifica.
- Diseña.

Información que falta

- Propósito y audiencia.
- Datos disponibles.
- Criterios y alcance.
- Formato esperado.

Mensaje clave

Una instrucción puede ser comprensible y, aun así, seguir siendo demasiado abierta para obtener una respuesta consistente.

Componentes del contexto

1. Objetivo: define el foco de la respuesta

2. Contexto: situación y uso

3. Datos: información disponible

4. Restricciones: límites y reglas

5. Ejemplos: patrón esperado

6. Formato: presentación del resultado

7. Criterios: cómo evaluar la calidad del resultado

Idea clave

Diseñar un prompt es construir el contexto desde el que el modelo identificará el problema.

Caso transversal: comentarios sobre un portal

Contexto

Una institución lanzó un nuevo portal y recibió estos comentarios de usuarios.

ID	Comentario
C01	El portal es claro, pero no encuentro el formulario para actualizar mis datos.
C02	Realicé el pago ayer y todavía no recibo confirmación.
C03	El botón para descargar el certificado no funciona desde mi celular.
C04	La información del programa está bien organizada.
C05	No sé a qué correo debo enviar los documentos.
C06	El sistema cerró mi sesión dos veces mientras completaba el formulario.

Actividad 1: diagnóstico

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Instrucción

Redacta un prompt para analizar los comentarios y recomendar qué debería hacer la institución.

- Escríbelo como lo harías normalmente.
- Guarda esta versión: la compararemos al final.
- No intentes que sea perfecto todavía.

Objetivo

Observar qué información solemos dejar implícita cuando pedimos una tarea en lenguaje natural.

DataLab UNAL

Primera versión: comprensible, pero vaga

Prompt inicial

Analiza estos comentarios y dime qué deberíamos mejorar.

- “Analizar” no define operación.
- No hay categorías.
- No se indica cómo priorizar.
- No se define audiencia.
- No hay formato verificable.
- No limita inferencias.

Idea clave

Vago no significa incomprensible: significa que admite demasiadas interpretaciones.

Prompt estructurado (1/2)

Objetivo, contexto y reglas

Una institución recibió seis comentarios sobre su nuevo portal. El equipo responsable necesita identificar los problemas reportados y decidir qué asuntos debe revisar primero.

Utiliza únicamente los comentarios proporcionados.

Para cada comentario:

1. Asigna una categoría entre: navegación, pagos, funcionamiento técnico, comunicación o comentario positivo.
2. Asigna una prioridad: alta, media o baja.
3. Justifica la decisión mediante una frase basada en el comentario.

Prompt estructurado (2/2)

Formato e incertidumbre

Devuelve una tabla con las columnas: ID, categoría, prioridad, evidencia y acción sugerida.

Después de la tabla, presenta tres recomendaciones generales ordenadas por prioridad.

No inventes causas técnicas, responsables ni datos que no aparezcan en los comentarios. Cuando la evidencia sea insuficiente, escribe: “Requiere revisión manual”.

Resultado esperado

La respuesta puede revisarse porque la tarea, las reglas y el formato son observables.

¿Qué cambió?

Elemento	Versión inicial	Versión estructurada
Tarea	Analizar	Clasificar, priorizar y recomendar
Información	Implícita	Comentarios delimitados
Reglas	Ausentes	Categorías y prioridades
Evidencia	No solicitada	Basada en el comentario
Formato	Libre	Tabla y recomendaciones
Incertidumbre	Ignorada	Revisión manual
Evaluación	Subjetiva	Requisitos observables

Lección

El contexto no solo acompaña la instrucción: también ayuda a definir qué tarea se está pidiendo.

Actividad 2: reconstruir el contexto

Laboratorio de Analítica de Datos - Sede Bogotá

UNIVERSIDAD NACIONAL DE COLOMBIA

Trabajo individual o en parejas

Toma tu prompt diagnóstico y agrega explícitamente los componentes que faltan.

- ¿Cuál es el objetivo observable?
- ¿Qué datos debe usar el modelo?
- ¿Qué restricciones debe respetar?
- ¿Qué formato debe devolver?
- ¿Qué debe hacer si falta información?

Producto

Una segunda versión del prompt, dividida por componentes.

DataLab UNAL

Una misma entrada, diferentes tareas

Idea

Los comentarios del portal son los mismos, pero el prompt puede pedir operaciones muy diferentes.

Familia	Operación principal
Informativa	Explicar, resumir, comparar o sintetizar.
Creativa	Proponer ideas, mensajes, campañas o versiones alternativas.
Instructiva	Diseñar procedimientos, planes, checklists o protocolos.
Clasificadora	Asignar etiquetas, prioridades, riesgos o decisiones.

Aclaración

Es una tipología didáctica. Una tarea real puede combinar varias familias.

Prompts informativos

Propósito

Obtener una explicación, síntesis, respuesta fundamentada o reorganización clara de la información.

Ejemplo contextualizado

Resume los comentarios sobre el portal para un comité directivo que no ha leído los mensajes originales.
Organiza la respuesta en: aspectos positivos, dificultades reportadas, posibles consecuencias para la experiencia del usuario y asuntos que requieren más información.
Diferencia las observaciones de los usuarios de cualquier interpretación. No agregues causas que no estén respaldadas por los comentarios. Máximo 180 palabras.

Prompts creativos

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Propósito

Generar ideas, historias, campañas, metáforas, guiones o propuestas abiertas.

Ejemplo contextualizado

Propón tres conceptos para una campaña interna que motive a los usuarios a utilizar el nuevo portal.
Público: estudiantes y personal administrativo con diferentes niveles de experiencia digital.
Cada concepto debe incluir nombre de la campaña, mensaje principal, pieza sugerida y llamada a la acción. Usa un tono cercano y profesional. Evita afirmar que el portal no presenta errores.

DataLab UNAL

Prompts instructivos

Propósito

Pedir un procedimiento, plan, checklist, protocolo o artefacto con restricciones.

Ejemplo contextualizado

Diseña un protocolo inicial para responder a los comentarios recibidos sobre el portal.
Incluye seis etapas: recepción del comentario, clasificación, asignación de prioridad, remisión al área responsable, comunicación con el usuario, y cierre del caso.
Para cada etapa, indica responsable por función, información necesaria y resultado esperado. Presenta la respuesta en una tabla.

Prompts clasificadores

Propósito

Asignar etiquetas o decidir entre opciones: sentimiento, temas, prioridad, riesgo, duplicados o rutas de atención.

Ejemplo contextualizado

Clasifica cada comentario en una categoría: navegación, pagos, funcionamiento técnico, comunicación o comentario positivo.
Asigna una sola categoría según el problema principal. Cuando dos categorías sean igualmente posibles, utiliza “Revisión manual”.
Devuelve una tabla con ID, categoría y evidencia textual de máximo doce palabras.

Actividad 3: una entrada, cuatro tareas

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Trabajo en grupos

Cada grupo diseña un prompt usando los mismos comentarios del portal, pero con una finalidad diferente.

- Grupo 1: resumen para directivos.
- Grupo 2: campaña para orientar usuarios.
- Grupo 3: protocolo de respuesta.
- Grupo 4: clasificación y prioridad.

Pregunta de cierre

¿Qué componentes del prompt cambiaron cuando cambió la finalidad?

DataLab UNAL

Del audio a los ejemplos

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Conexión

En el audio, una palabra escrita antes de escuchar puede orientar la interpretación. En un prompt, una demostración previa también puede orientar cómo se procesa una nueva entrada.

DataLab UNAL

In-context learning (ICL)

Laboratorio de Analítica de Datos – Sede Bogotá –

UNIVERSIDAD NACIONAL DE COLOMBIA

Definición

El **in-context learning** ocurre cuando el modelo adapta temporalmente su comportamiento usando instrucciones y demostraciones dentro del contexto, **sin actualizar sus parámetros**.

- No equivale a reentrenar el modelo.
- No garantiza aprendizaje permanente.
- Depende de la calidad de instrucciones y ejemplos.

Tres formas frecuentes

Zero-shot: sin ejemplos. One-shot: un ejemplo. Few-shot: pocos ejemplos.

DataLab UNAL

El contexto no vale por su longitud

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Contexto útil

- Suficiente.
- Relevante.
- Coherente.
- Bien estructurado.
- Representativo.

Contexto perjudicial

- Ejemplos incorrectos.
- Instrucciones contradictorias.
- Información irrelevante.
- Etiquetas inconsistentes.
- Formatos mezclados.

Regla práctica

Más contexto no siempre significa mejor contexto.

DataLab UNAL

Zero-shot

Idea central

El modelo recibe instrucciones, reglas y formato, pero no recibe ejemplos resueltos.

Ejemplo

Clasifica cada comentario utilizando una de estas categorías: navegación, pagos, funcionamiento técnico, comunicación o comentario positivo.
Aplica las definiciones proporcionadas y selecciona la categoría correspondiente al problema principal. Cuando no exista evidencia suficiente, utiliza “Revisión manual”.
Devuelve una tabla con: ID, categoría y evidencia. No se proporcionan ejemplos resueltos.

Clave

Zero-shot no significa ausencia de estructura.

One-shot

Idea central

Se agrega un ejemplo resuelto para mostrar criterio, formato o estilo esperado.

Ejemplo

Ejemplo resuelto:
Comentario: “No encuentro dónde descargar la factura.”
Resultado: ID = E01; categoría = navegación; evidencia = “No encuentra la opción de descarga”.
Ahora clasifica los comentarios C01 a C06 siguiendo las mismas reglas y el mismo formato.

Riesgo

Un único ejemplo puede orientar demasiado la respuesta si no representa bien la tarea.

Few-shot

Idea central

Se incluyen varios ejemplos representativos para enseñar criterio, formato y casos borde.

Comentario de ejemplo	Categoría	Qué enseña
El enlace para recuperar la contraseña genera un error.	Funcionamiento técnico	Un caso claro de falla.
El proceso fue rápido y la información resultó clara.	Comentario positivo	Una valoración favorable.
No sé dónde consultar si mi pago fue aprobado.	Revisión manual	Caso ambiguo entre navegación y pagos.

Clave

Los ejemplos deben enseñar diferencias útiles, no repetir casos casi idénticos.

Comparación: zero-shot, one-shot y few-shot

Técnica	Qué contiene	Ventaja	Riesgo
Zero-shot	Instrucciones y reglas	Rápido y económico	Ambigüedad
One-shot	Una demostración	Aclara formato o criterio	Anclaje
Few-shot	Varias demostraciones	Muestra patrones y casos borde	Sesgo por ejemplos

Regla práctica

Primero se aclaran la tarea y las reglas. Después se decide si hacen falta ejemplos.

Riesgos del in-context learning

- **Selección:** ejemplos poco representativos inducen criterios incorrectos.
- **Orden:** la secuencia de ejemplos puede influir en la salida.
- **Anclaje:** un ejemplo puede dominar casos diferentes.
- **Contradicción:** una demostración puede entrar en conflicto con la instrucción.
- **Costo de contexto:** más ejemplos consumen espacio, tiempo y recursos.

Observación

El diseño de ejemplos debe evaluarse igual que el resto del prompt.

Actividad 4: tríada de prompting

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Instrucción

Para una misma tarea, redacta tres versiones: **zero-shot**, **one-shot** y **few-shot**.

- Usen los mismos datos y el mismo formato de salida.
- Definan un criterio de calidad antes de ejecutar.
- Comparen claridad, consistencia, costo y manejo de casos ambiguos.

Objetivo

Comprender cómo cambia la respuesta cuando agregamos demostraciones al contexto.

DataLab UNAL

Cuando la tarea exige razonar

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Problema típico

Algunas tareas requieren múltiples pasos: cálculos, deducciones, comparación de condiciones o descomposición de un problema.

- Un prompt directo puede fallar aunque la pregunta parezca simple.
- En estos casos conviene organizar el proceso, no solo mejorar la redacción.

Transición

Los ejemplos muestran qué tarea realizar. Las estrategias de razonamiento ayudan a ordenar cómo resolverla.

DataLab UNAL

Caso de referencia: presupuesto

Situación

Una institución dispone de **COP 18.000.000** para adquirir una herramienta digital.

Concepto	Costo
30 licencias, cada una de COP 350.000	COP 10.500.000
Capacitación	COP 2.400.000
Soporte anual	COP 1.800.000
Reserva sobre los costos anteriores	10 %

Pregunta

¿El presupuesto es suficiente y cuánto dinero quedaría disponible?

Prompt estándar

Versión directa

Determina si el presupuesto es suficiente.

- No indica qué costos incluir.
- No define la base de la reserva.
- No solicita mostrar operaciones.
- No pide verificación.
- No define formato.
- Puede ocultar errores de cálculo.

Idea

En tareas de varios pasos, la respuesta final no basta: necesitamos que el proceso sea verificable.

Chain-of-Thought (CoT)

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Idea central

CoT induce al modelo a producir o seguir pasos intermedios para resolver tareas multi-paso.

Uso práctico

Descompón el cálculo en: costo de licencias, costos adicionales, reserva, costo total y saldo. Muestra únicamente los cálculos necesarios y termina con una conclusión de una frase.

- Puede mejorar tareas aritméticas, lógicas o simbólicas.
- No es magia: debe evaluarse según la tarea.
- Conviene pedir pasos verificables, no explicaciones innecesarias.

DataLab UNAL

Zero-shot CoT

Idea central

A veces basta una instrucción breve para inducir pasos intermedios, como “pensemos paso a paso”.

Versión más específica

Resuelve el problema siguiendo estas etapas:

1. calcula el costo de licencias;
2. suma capacitación y soporte;
3. calcula la reserva del 10 %;
4. obtiene el costo total;
5. compáralo con el presupuesto;
6. verifica nuevamente las operaciones.

Presenta los resultados en una tabla y una conclusión breve.

CoT few-shot

Idea central

Se muestra un ejemplo resuelto para enseñar el procedimiento esperado.

Ejemplo de demostración

Presupuesto: COP 10.000.000. Costos directos: COP 8.000.000. Reserva: 10 % = COP 800.000. Total: COP 8.800.000. Saldo: COP 1.200.000. Conclusión: el presupuesto es suficiente.

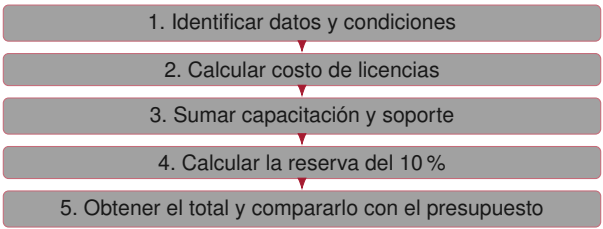
Uso

Después del ejemplo, se pide aplicar el mismo procedimiento al nuevo caso, conservando el formato.

Least-to-Most

Estrategia en dos etapas

1. Descomponer un problema en subproblemas. **2.** Resolverlos secuencialmente usando resultados previos.



Idea clave

La estrategia ayuda cuando la solución depende de resultados intermedios.

Generated Knowledge Prompting

Idea central

Primero se pide al modelo generar conocimiento o criterios relevantes; luego se reutilizan como contexto para resolver la tarea.

Ejemplo en dos fases

Fase 1: enumera criterios para evaluar una compra de software con presupuesto limitado.
Fase 2: aplica únicamente los criterios verificables con los datos disponibles.

Advertencia

El conocimiento generado también puede contener errores. Debe verificarse antes de utilizarlo como fundamento.

Self-Consistency

Idea central

En vez de confiar en una sola trayectoria, se generan varias soluciones y se compara la respuesta final.

- Busca estabilidad en problemas de razonamiento.
- Aumenta el costo computacional y de revisión.
- Es útil cuando la consistencia importa más que la rapidez.

Precaución

Que varias respuestas coincidan no garantiza que sean verdaderas. La verificación sigue siendo necesaria.

Comparación de estrategias

Estrategia	Aporta	Riesgo
Prompt estándar	Rapidez	Omisión de pasos
Zero-shot CoT	Descomposición inicial	Pasos genéricos
CoT few-shot	Patrón explícito	Anclaje al ejemplo
Least-to-Most	Resolución secuencial	Mayor longitud
Generated Knowledge	Contexto previo	Propagar errores
Self-Consistency	Estabilidad	Mayor costo

Criterio práctico

No se elige la técnica por moda; se elige según la tarea, el riesgo y la necesidad de verificación.

Actividad 5: mismo problema, varios diseños

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Trabajo en equipos

Resuelvan el caso presupuestal con cuatro diseños: estándar, Zero-shot CoT, Least-to-Most y una técnica adicional.

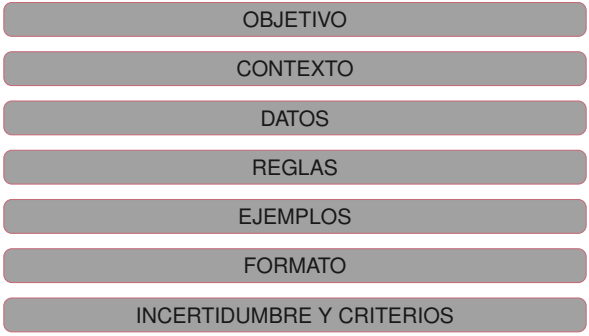
- Comparen respuesta final y proceso.
- Evalúen exactitud, claridad, longitud y facilidad de verificación.
- Justifiquen qué diseño ofrece el mejor balance.

Objetivo

Aprender a elegir estrategias de razonamiento con evidencia, no por intuición.

DataLab UNAL

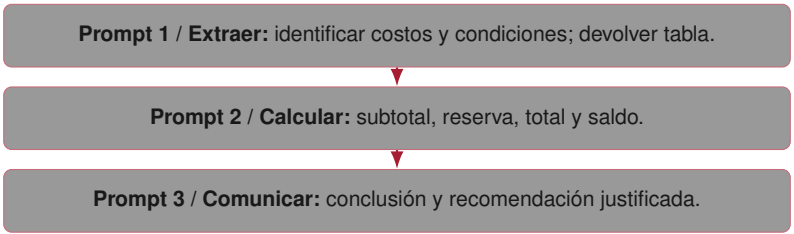
El prompt como artefacto modular



Idea clave

Modularizar permite modificar una parte sin reescribir todo el prompt.

Prompt chaining: encadenar instrucciones



- Cada salida puede alimentar la siguiente etapa.
- Se puede revisar una etapa sin reescribir todo el flujo.
- Un error temprano también puede propagarse: valida las transiciones.

Plantilla modular sugerida

Estructura base

Objetivo: resultado esperado.
Contexto de uso: quién utilizará la respuesta y para qué.
Datos: información que debe procesarse, separada de las instrucciones.
Reglas: condiciones, restricciones y criterios de decisión.
Ejemplos: demostraciones opcionales.
Formato: estructura exacta de salida.
Cuando falte información: conducta esperada.
Criterios de calidad: cómo se evaluará la respuesta.

Advertencia

No es una ley universal. Es una herramienta pedagógica que debe adaptarse y validarse en cada tarea.

Adaptabilidad

Tarea	Componentes que más importan
Clasificación	Etiquetas, definiciones, casos ambiguos y formato estructurado.
Creación	Audiencia, propósito, tono, restricciones creativas y ejemplos de estilo.
Razonamiento	Datos, pasos, supuestos, operaciones y verificación.
Planificación	Recursos, restricciones, responsables, etapas e indicadores.

Lección

Un prompt útil es portable con ajustes, no rígido.

¿Cuándo aporta un rol?

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Rol funcional

Actúa como analista de experiencia de usuario. Organiza los comentarios para ayudar al equipo responsable a priorizar problemas.

Rol decorativo

Actúa como el mejor analista del mundo, con capacidades excepcionales y visión superior.

Regla práctica

El rol es útil cuando modifica el enfoque, la audiencia o los criterios. No reemplaza el objetivo, los datos ni las reglas.

DataLab UNAL

Evaluación: diseñar para medir

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Principio central

La calidad del prompt se determina ejecutándolo en una tarea y comparando resultados, no solo leyendo su redacción.

- Definir criterios antes de ejecutar.
- Crear casos de prueba, incluyendo casos borde.
- Comparar variantes del prompt.
- Documentar versiones y resultados.

Idea

Un prompt puede sonar completo y aun así fallar en condiciones reales.

DataLab UNAL

Criterios de evaluación

Para clasificación

- Usa todas las entradas.
- Conserva los ID.
- Emplea categorías permitidas.
- Justifica con evidencia.
- Identifica casos ambiguos.

Para razonamiento

- Usa todos los datos.
- Realiza operaciones correctas.
- Aplica bien las restricciones.
- Verifica el resultado.
- Concluye de forma coherente.

Mensaje

La evaluación debe ajustarse al tipo de tarea.

Rúbrica simple para evaluar prompts

Criterio	0	1	2
Cumplimiento	No cumple	Parcial	Completo
Fidelidad	Inventa	Mezcla hechos e inferencias	Se limita a los datos
Cobertura	Omite elementos	Cubre algunos	Cubre todos
Formato	Incorrecto	Parcial	Correcto
Claridad	Confuso	Aceptable	Claro
Incertidumbre	La oculta	Parcial	La gestiona

Uso

Aplicar la rúbrica en revisión por pares antes de usar el prompt en una tarea real.

Casos de prueba

Tipo de caso	Ejemplo
Normal	No puedo descargar el certificado.
Positivo	La información está organizada y fue fácil completar el proceso.
Ambiguo	No sé si mi pago quedó registrado.
Insuficiente	No funciona.
Dos problemas	No encuentro el formulario y el portal cierra mi sesión.

Pregunta

¿Qué debería hacer el modelo en cada caso? La respuesta debe estar prevista por el prompt.

Pruebas A/B

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Regla

Cambiar un solo componente del prompt cada vez.

Versión A

Categorías sin definiciones.

Versión B

Categorías con definiciones y regla para casos ambiguos.

Mantener constantes: modelo, datos, ejemplos, formato, configuración y criterios de evaluación.

Objetivo

Atribuir la diferencia al cambio realizado, no a varias modificaciones mezcladas.

DataLab UNAL

Errores comunes al diseñar prompts

- Usar verbos demasiado generales: “analiza”, “explica”, “mejora”.
- Aportar mucho contexto irrelevante.
- Mezclar instrucciones contradictorias.
- No delimitar los datos de entrada.
- No definir etiquetas o criterios de decisión.
- Seleccionar ejemplos sesgados o inconsistentes.
- Evaluar con un único caso.
- Modificar muchas partes del prompt al mismo tiempo.

Consecuencia

Se vuelve difícil evaluar, depurar y reproducir resultados.

Buenas prácticas y checklist final

- Definir objetivo y criterio de éxito.
- Separar instrucciones, datos y ejemplos.
- Especificar formato: tabla, lista, JSON, pasos o informe.
- Indicar qué hacer cuando falta información.
- Crear casos de prueba, incluyendo casos borde.
- Hacer pruebas A/B y registrar versiones.
- Elegir técnica según la tarea, no por costumbre.

Resumen

Un prompt profesional es una hipótesis que debe probarse.

Actividad integradora: paquete de prompts

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

Producto del equipo

Diseñen un paquete de prompts sobre un problema real de su contexto académico, administrativo, financiero o técnico.

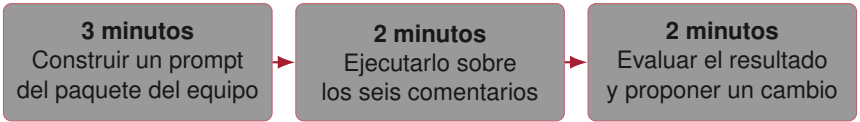
- Un prompt informativo.
- Un prompt creativo o de transformación.
- Un prompt instructivo.
- Un prompt clasificador.
- Versiones zero-shot, one-shot y few-shot de uno de ellos.
- Una estrategia de razonamiento para una tarea compleja.
- Seis casos de prueba, incluyendo dos casos borde.

Entrega

Presenten el paquete y expliquen qué cambió entre la primera y la última versión.

DataLab UNAL

Taller: construir, probar y evaluar



Entregable del ejercicio

Conserva el **prompt original**, el **prompt mejorado** y un ejemplo de respuesta. Identifica qué componente mejoró la verificación del resultado.

Idea clave

No es obligatorio usar few-shot. Decide si los ejemplos aportan valor.

Cierre narrativo

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

En la percepción

- Señal acústica.
- Expectativas.
- Contexto previo.
- Condiciones de escucha.

En un prompt

- Instrucción.
- Objetivo.
- Datos y contexto.
- Reglas y ejemplos.

Límite de la comparación

Un LLM no escucha ni interpreta como una persona. La analogía permite comprender que una entrada nunca actúa completamente aislada de su contexto.

DataLab UNAL

Una instrucción no siempre define por sí sola una tarea.

El contexto ayuda al modelo a decidir qué problema debe resolver.

Cuando la respuesta no es la esperada, también debemos revisar el contexto que construimos.

Bibliografía y referencias

- Bosker, H. R. (2018). *Putting Laurel and Yanny in context*. The Journal of the Acoustical Society of America, 144(6), EL503–EL508.
- Brown, T. B. et al. (2020). *Language Models are Few-Shot Learners*. NeurIPS 33.
- Wei, J. et al. (2022). *Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*.
- Kojima, T. et al. (2022). *Large Language Models are Zero-Shot Reasoners*.
- Zhou, D. et al. (2023). *Least-to-Most Prompting Enables Complex Reasoning in Large Language Models*.
- Wang, X. et al. (2023). *Self-Consistency Improves Chain of Thought Reasoning in Language Models*.
- Liu, P. et al. (2023). *Pre-train, Prompt, and Predict: A Systematic Survey of Prompting Methods in Natural Language Processing*.
- Zhu, K. et al. (2024). *PromptBench: Towards Evaluating the Robustness of Large Language Models on Adversarial Prompts*.
- Referencias periodísticas sobre el audio “bicicleta/alquiler”: La Sexta y TN, marzo de 2021.

Laboratorio de Analítica de Datos - Sede Bogotá -

UNIVERSIDAD NACIONAL DE COLOMBIA

¡Gracias!

DataLab UNAL